

UNIVERZITET U BEOGRADU
FAKULTET ORGANIZACIONIH NAUKA

ZAVRŠNI RAD

**Predviđanje trenda Bitcoin-a korišćenjem
LSTM mreža pomoću tehničkih indikatora**

Mentor

Dr Aleksandar Rakićević,

Docent

Student

Nađa Markićević, 2021/0283

Beograd, 2025. godine

*Posvećujem ovaj rad mojim roditeljima i sestri,
kao mali znak zahvalnosti za njihovu beskrajnu i bezulovnu podršku...*

APSTRAKT

Tržište kriptovaluta je jedno od najdinamičnijih i najnestabilnijih tržišta savremenog finansijskog sistema. Njegova nepredvidivost i brze promene otežavaju analizu i donošenje investicionih odluka. Zbog toga je interesovanje za razvijanjem uspešnih i preciznih modela za analizu tržišta kriptovaluta sve veće. Cilj ovog rada je razvoj modela za predviđanje trenda kretanja *Bitcoin*-a na osnovu istorijskih podataka i tehničkih indikatora. Problem je posmatran i kao klasifikacioni i kao regresioni, a izabrani model je *LSTM* neuronska mreža zbog svoje sposobnosti da obrađuje sekvencijalne podatke i prepozna vremenske obrasce. Implementacija je izvršena u programskom jeziku *Python*, uz korišćenje pomoćnih biblioteka. Rezultati ukazuju na bolju uspešnost regresionog pristupa predviđanju naspram klasifikacionog

SADRŽAJ

1	UVOD.....	1
2	TEORIJSKE OSNOVE	2
2.1	NEURONSKE MREŽE.....	2
2.1.1	LSTM mreže.....	5
2.2	KRIPTOVALUTE	7
2.2.1	Bitcoin	8
2.3	TEHNIČKA ANALIZA	10
2.3.1	Stohastički oscilator.....	10
2.3.2	Indeks robnog kanala.....	11
2.3.3	Brzina promene.....	11
2.3.4	Pokretni prosek konvergencija/divergencija	11
2.3.5	Parabolički pokazatelj zaustavljanja i preokreta	12
2.3.6	Bolindžerov kanal.....	12
2.3.7	Supertrend.....	12
2.3.8	Indeks relativne snage	13
2.3.9	Indeks novčanog toka	13
2.3.10	Čandeov oscilator momentuma	14
2.3.11	Prosečni indeks smera	14
2.3.12	Indeks korelacije ranga.....	14

3	OPIS PROBLEMA	15
4	PREDLOŽENA METODOLOGIJA	16
4.1	PREUZIMANJE I PRIPREMA PODATAKA	17
4.2	KREIRANJE CILJNE PROMENLJIVE	17
4.2.1	Klasifikacioni problem	18
4.2.2	Regresioni problem.....	19
4.3	FORMIRANJE NIZA ULAZNIH PROMENLJIVIH	19
4.4	KREIRANJE SEKVENCI PODATAKA	20
4.5	TRENIRANJE LSTM MREŽE	21
4.6	EVALUACIJA PERFORMANSI.....	22
5	REZULTATI	24
5.1	KLASIFIKACIONI PROBLEM	25
5.2	REGRESIONI PROBLEM	28
6	ZAKLUČAK	32
	LITERATURA	33

1 UVOD

Razvoj naprednih tehnologija, poput mašinskog i dubokog učenja, omogućio je analizu i rešavanje kompleksnih problema koji stvaraju prepreke tradicionalnim pristupima. Jedan od takvih problema je i analiza i predviđanje kretanja složenih finansijskih tržišta kao što je tržište kriptovaluta. Ovo tržište karakterišu visoka volatilnost, nestabilnost i nepredvidivost.

Iako danas veoma popularno, tržište kriptovaluta predstavlja izazov za razumevanje i aktivno učestvovanje, pa je česta tema razgovora i istraživanja novih pristupa sa ciljem postizanja pouzdanijih rezultata. Njegova nelinearnost i kompleksnost onemogućavaju primenu jednostavnih modela, već se primenjuju složeni i hibridni modeli zasnovani na veštačkoj inteligenciji.

U ovom radu kao model je izabrana *LSTM* mreža, sa idejom da će njena sposobnost obrade sekvencijalnih podataka imati uspešnost u uočavanju obrazaca u kretanju cene koji se formiraju s vremenom. Kao osnov za predviđanje, korišćeni su tehnički indikatori kako bi se otkrile „skrivenne informacije“ u tržišnoj ceni *Bitcoin*-a.

Problem je posmatran iz dva ugla, prvo kao klasifikacioni, a zatim kao regresioni problem. Zadatak klasifikacije je da razvrsta kretanje cene u klase koje karakteriše određeni smer kretanja cene (rastući, neutralni i opadajući). Sa druge strane, zadatak regresije je da opiše trend na osnovu predviđene vrednosti pokretnog proseka cene.

U narednom poglavlju dat je pregled literature sa objašnjenjima svih važnih koncepata, nakon čega, u trećem poglavlju, sledi detaljan opis problema. U četvrtom poglavlju predstavljena je metodologija sa svim koracima izvedenog eksperimenta, a u petom su dati prikaz i tumačenje rezultata. Na kraju, u šestom poglavlju su formulisani zaključci čitavog istraživanja.

2 TEORIJSKE OSNOVE


U ovom poglavlju dat je pregled ključnih teorijskih koncepata na kojima se temelji istraživanje. Objašnjen je princip funkcionisanja neuronskih mreža sa posebnim osvrtom na *LSTM* mreže i njene pogodnosti. Pored toga, približeni su pojmovi kriptovaluta i *Bitcoin*-a, kao i značaj tehničke analize i tehničkih indikatora u proučavanju finansijskih tržišta.

2.1 NEURONSKE MREŽE

Neuronske mreže predstavljaju računarske modele inspirisane načinom na koji funkcionišu neuroni ljudskog mozga (McNelis, 2005). Sastoje se od međusobno povezanih jedinica, veštačkih neurona, koji primaju, obrađuju i prenose informacije - poput ljudskih neurona. Osnovni elementi jednog veštačkog neurona su sledeći:

- Sinapse - veze između neurona sa pridruženim težinskim koeficijentima;
- Sabirač - komponenta koja sabira ulazne signale;
- Aktivaciona funkcija - funkcija koja omogućava da mreža uči odnose ulaza i izlaza, najčešće na nelinearan način poput *sigmoid*, *tanh* i *ReLU* funkcija.

Na Slici 1 prikazan je model veštačkog neurona sa svim elementima.



Slika 1. Model veštačkog neurona k (prilagođeno prema Haykin, 2009)


Neuron k se može predstaviti i matematički pomoću formula:

$$u_k = \sum_{j=1}^m w_{kj} x_j \quad (1)$$

$$y_k = \varphi(u_k + b_k) = \varphi(v_k) \quad (2)$$

gde su $x_1, x_2, \dots, x_m$ ulazni podaci, $w_{k1}, w_{k2}, \dots, w_{km}$ odgovarajući težinski koeficijenti, b_k pristrasnost, v_k ukupna aktivacija neurona, φ aktivaciona funkcija, y_k izlaz neurona (Haykin, 2009).

Međusobno povezani neuroni grade slojeve neuronske mreže. Svaka mreža ima ulazni i izlazni sloj, a između njih može imati nula ili više skrivenih slojeva. Najjednostavniji tip mreže naziva se perceptron. Perceptron nema skrivenih slojeva i sve transformacije ulaza se odigravaju u izlaznom neuronu, pa se naziva i jednoslojna mreža (Aggarwal, 2018). Mreže sa jednim ili više skrivenih slojeva nazivaju se višeslojne (eng. *Multilayer Perceptron, MLP*).



Slika 2. Višeslojna neuronska mreža (prilagođeno prema Haykin, 2009)

Na Slici 2 prikazan je model višeslojne neuronske mreže sa jednim skrivenim slojem. Podaci se u ovakvoj mreži od ulaza prenose preko skrivenih slojeva do izlaznog sloja. Uvođenjem dodatnih skrivenih slojeva postiže se značajno veća prediktivna moć.

Proces učenja *MLP* neuronske mreže iz ulaznih podataka naziva se treniranje i pripada tipu nadgledanog učenja (eng. *supervised learning*). To znači da mreža uči na parovima ulaz-izlaz i ima cilj da nauči da što preciznije predviđa izlaz na osnovu ulaza.

Koraci treniranja neuronske mreže su sledeći (Gurney, 1997);:

1. Priprema podataka - podela podataka na skup za treniranje i skup za testiranje;
2. Prosleđivanje napred (eng. *Forward pass*) - prolazak ulaznih informacija kroz slojeve mreže, njihova obrada i dobijanje izlaza;
3. Računanje funkcije greške - računanje odstupanja predviđene od stvarne vrednosti, u cilju njenog smanjenja;
4. Prostiranje unazad (eng. *Backpropagation*) - računanje parcijalnih derivata funkcije greške u odnosu na svaki težinski koeficijent, greška se šalje od izlaznog ka ulaznom sloju;
5. Ažuriranje parametara - vrši se optimizacija težinskih koeficijenata sa ciljem smanjenja greške.


Na osnovu strukture povezanih neurona i načina prenošenja informacija, mreže se mogu podeliti u više tipova:

1. Mreže sa prostiranjem u napred (eng. *Feedforward*) mreže - informacije se kreću u jednom smeru, od ulaza ka izlazu;
2. Rekurentne neuronske mreže (eng. *Recurrent Neural Networks, RNN*) - informacije se kreću u oba smera zahvaljujući povratnim vezama, što omogućava pamćenje stanja;
3. Konvolucione neuronske mreže (eng. *Convolutional Neural Network, CNN*) - imaju mogućnost prepoznavanja prostornih obrazaca, što ih čini pogodnim za obradu slika.

2.1.1 LSTM mreže

LSTM (Long Short-Term Memory) mreže su poseban tip rekurentnih mreža kreiran za modelovanje sekvencijalnih podataka kroz duže vremenske intervale. Kao što je već pomenuto, rekurentne mreže su višeslojne neuronske mreže sa povratnom spregom i one propagiraju podatke unapred, kao i klasične, ali i unazad. Time se postiže da prethodno stanje utiče na buduće izlaze, čime se omogućava „pamćenje“ informacija.

Međutim, klasične *RNN* mreže imaju ograničenu mogućnost učenja dugoročnih zavisnosti. Ovaj nedostatak *LSTM* mreže rešavaju uvođenjem novih elemenata koji čine neurone kompleksnijim, te se često njihovi neuroni nazivaju i ćelije (Brownlee, 2017). Ključni elementi su stanje ćelije (eng. *cell state*) i mehanizmi poznati kao vrata (eng. *gates*).



Slika 3. Razvijeni model ćelije *LSTM* mreže¹

Na Slici 3 je prikazana razvijena ćelija *LSTM* mreže sa svim važnim elementima. Gornja, prava linija koja prolazi kroz neuron predstavlja stanje ćelije i ona omogućava protok gotovo nepromenjenih informacija. Stanje ćelije čuva važne informacije čije ažuriranje kontrolišu vrata, mehanizmi neurona koji kontrolišu protok informacija. Svaka vrata su sastavljena iz sigmoidnog sloja i operacije množenja. Sigmoidni sloj proizvodi vrednost od nula do jedan koja određuje deo informacija koji će biti propušten. Vrednost nula potpuno blokira protok, dok vrednost jedan propušta sve informacije. Ovo čini proces kontrole protoka informacija adaptivnim na trenutno stanje.

¹ <https://colah.github.io/posts/2015-08-Understanding-LSTMs/> , datum pristupa: 06.10.2025.

Prema funkciji koju vrše, vrata se dele na tri tipa:


1. Ulazna vrata (eng. *input gate*) - odlučuju koji deo informacija koji je stigao do neurona će zaista i ući u unutrašnje stanje neurona;
2. Izlazna vrata (eng. *output gate*) - odlučuju koji deo generisanog izlaza će napustiti neuron i biti prosleđen sledećem sloju;
3. Vrata zaborava (eng. *forget gate*) - odlučuju koji deo prethodnog unutrašnjeg stanja neurona treba zaboraviti, tj. ukloniti iz memorije neurona (Brownlee, 2017).

Ovako konstruisane *LSTM* mreže prevazilaze problem ograničenog učenja dugoročnih zavisnosti, osnovni problem rekurentnih mreža, i omogućavaju stabilno treniranje i učenje tokom velikih vremenskih koraka. Ovo ih čini pogodnim za primenu u velikom broju oblasti, poput obrade vremenskih serija, teksta, zvuka i drugih sekvencijalnih informacija.

2.2 KRIPTOVALUTE

Kriptovaluta predstavlja oblik digitalnog novca koji koristi napredne metode enkripcije radi obezbeđenja sigurnog kreiranja i prenosa sredstava. Funkcionišu bez centralne institucije, poput banke ili vlade, čime se omogućava decentralizovan finansijski sistem. (Schueffel i dr, 2019)

Funkcionisanje kriptovaluta zasniva se na blokčejn (eng. *blockchain*) tehnologiji, koja predstavlja distribuiranu bazu podataka. U okviru blokčejn tehnologije, transakcije se zapisuju u blokove koji se međusobno povezuju kriptografskim heš (eng. *hash*) funkcijama. Svaki blok sadrži vremenski pečat i informacije o prethodnom bloku, što obezbeđuje nepromenljivost i transparentnost podataka. (Yaga i dr, 2018).



Slika 4. Generisanje lanca blokova (prilagođeno prema Yaga i dr, 2018)

Na Slici 4 prikazan je proces dodavanja novih blokova u lanac kroz vreme.

Pojava *Bitcoin*-a, 2009. godine označila je početak ere kriptovaluta i njihov ubrzan razvoj, pa se danas na tržištu nalazi na hiljade različitih kriptovaluta. Različite kriptovalute zasnivaju se na specifičnim tehnologijama, algoritmima konsenzusa i imaju različite namene, ali sve dele zajedničku ideju o decentralizovanom finansijskom sistemu.

2.2.1 Bitcoin

Bitcoin je prvi put predstavljen 2008. godine u radu pod nazivom „Bitcoin: A Peer-to-Peer Electronic Cash System“, koji je objavio autor pod pseudonimom Satoshi Nakamoto. (Antonopoulos, 2017). Sistem je pokrenut u januaru naredne godine kada je izdat prvi blok, poznat kao *Genesis Block*.

Za razliku od tradicionalnih valuta, *Bitcoin* ne postoji u fizičkom obliku. Vrednost koju korisnik poseduje zapisana je u transakcijama na blokčejnu, a dokaz o vlasništvu nad određenom količinom je kriptografski ključ. Korisnik sve kriptografske ključeve čuva u svom digitalnom novčaniku (eng. *wallet*).

Svaka transakcija ima ulaze i izlaze: ulaz sadrži reference na prethodne transakcije, a izlaz podatke o novom vlasniku i iznosu koji mu se prenosi (Yaga i dr, 2018). Ovakva kriptografska povezanost svakog bloka sa prethodnim čini jednom kreirane transakcije nepovratnima i nepromenljivima. Razlika između ulazne i izlazne sume transakcije čini transakcionu nadoknadu. Verifikovanje transakcija se vrši unutar mreže korisnika poznatih kao rudari (eng. *miners*), a proces potvrđivanja transakcija i dodavanja novih blokova u lanac poznat je pod nazivom rudarenje ili kopanje (eng. *minning*) (Schueffel, 2019).

Zadatak rudara je da reši složeni matematički problem brže od ostalih učesnika mreže. Rešenje problema uključuje se u novonastali blok i naziva se *Proof of Work*. *Proof of Work (PoW)* je algoritam konsenzusa koji obezbeđuje da svaki rudar mora da uložiti značajne resurse da bi došao do rešenja. Potrošnja određene količine snage i energije pri svakom dodavanju novog bloka čini napade i manipulacije neisplativim. Kao nadoknadu za svoj doprinos mreži, rudari dobijaju nove jedinice valute i transakcione nadoknade, čime se i reguliše proces emitovanja valute (Antonopoulos, 2017).

Pored kontrolisanog načina stvaranja novih jedinica, *Bitcoin* karakteriše i ograničena ponuda od maksimalno 21 milion jedinica, za razliku od tradicionalnih valuta koje nemaju gornje ograničenje emitovanja. Proces koji obezbeđuje maksimum od 21 milion jedinica naziva se *halving*, koji predstavlja polovljenje nadoknade koju rudari primaju nakon svakog 210.000. iskopanog bloka (Schueffel, 2019). Ovim se dobija deflatorni karakter i povećava se njegova vrednost u odnosu na klasične valute. Sa početnom vrednošću manjom od jednog dolara tokom prvih godina postojanja, *Bitcoin* je do danas dostigao

cenu od oko 120.000 dolara. Na Slici 5 prikazano je kretanje cene *Bitcoin*-a od njegovog nastanka 2009. pa sve do 2025. godine.



Slika 5. Kretanje cene *Bitcoin*-a od 2009. do 2025. godine²

Nakon dugogodišnjeg prisustva na tržištu, *Bitcoin* je postao najpoznatija i najlikvidnija kriptovaluta današnjice. Prisutan je na velikom broju globalnih berzi, a broj njegovih korisnika i obim transakcija konstantno rastu, što ga čini pouzdanim, relevantnim i lako dostupnim primerom za analizu tržišnih trendova.

² <https://charts.bitbo.io/price/#article-sources> , datum pristupa: 04.10.2025.

2.3 TEHNIČKA ANALIZA

Tehnička analiza predstavlja pristup analizi finansijskih tržišta koji se zasniva na istorijskim podacima o kretanju cene i obimu trgovanja (Edwards i dr, 2019). Nasuprot fundamentalnoj analizi, čiji je fokus na ekonomskim i finansijskim pokazateljima, tehnička analiza polazi od pretpostavke da su svi važni podaci već ugrađeni u cenu.

Tehnički indikatori predstavljaju matematičke transformacije nad podacima o ceni i obimu trgovanja, koje omogućavaju identifikaciju trenda, momentuma i mogućih preokreta na tržištu. Cilj je dobiti vrednosti koje će pomoći pri predviđanju budućih promena cene.

U tehničkoj analizi se za izračunavanje indikatora najčešće koriste četiri osnovne vrednosti cene poznate kao cena na otvaranju (eng. *Open*), na zatvaranju (eng. *Close*), najviša (eng. *High*) i najniža cena (eng. *Low*). Još jedna često korišćena vrednost cene je tipična cena (eng. *Typical Price, TP*) koja se izračunava kao prosečna vrednost najviše, najniže i cene na zatvaranju.

2.3.1 Stohastički oscilator

Stohastički oscilator (eng. *Stochastic Oscillator*) meri poziciju trenutne cene u odnosu na njen raspon u određenom vremenskom periodu. Ideja je da se pri rastućem trendu cene zatvaranja približavaju gornjoj granici raspona, a pri opadajućem trendu se približavaju donjoj granici. Predstavlja se pomoću dve linije, glavne i signalne. Glavna linija se obeležava sa %K, a signalna sa %D i predstavlja pokretnu srednju vrednost glavne (Achelis, 2000).

Formula za glavnu liniju oscilatora je:

$$\%K_n = \frac{(C_n - L_n)}{(H_n - L_n)} * 100 \quad (3)$$

gde je C_n cena zatvaranja, L_n najniža cena za period n , H_n najviša cena za period n (Kirkpatrick II i Dahlquist, 2015).

2.3.2 Indeks robnog kanala

Indeks robnog kanala (eng. *Commodity Channel Index, CCI*) meri poziciju trenutne cene u odnosu na njenu prosečnu vrednost za određeni period. Vrednost indikatora obično oscilira unutar opsega -100 do 100, ali može i premašiti ove granice prilikom jakih trendova (Achelis, 2000). Formula glasi:

$$CCI_n = \frac{TP_n - SMA_n(TP)}{0.015 * MD_n} \quad (4)$$

gde je TP_n tipična cena, $SMA_n(TP)$ pokretna srednja vrednost tipične cene za period n , MD_n srednje odstupanje cene od proseka za period n .

2.3.3 Brzina promene

Brzina promene (eng. *Rate of Change, ROC*) meri stopu promene trenutne cene u odnosu na cenu pre određenog perioda. Opseg vrednosti je od -100 do 100, gde pozitivne vrednosti ukazuju na rast, a negativne na pad cene. Formula za izračunavanje brzine promene je:

$$ROC_n = \frac{C_n - C_{n-T}}{C_{n-T}} * 100 \quad (5)$$

gde je C_n trenutna cena zatvaranja n perioda, C_{n-T} cena zatvaranja $n-T$ perioda (Achelis, 2000).

2.3.4 Pokretni prosek konvergencija/divergencija

Pokretni prosek konvergencija/divergencija (eng. *Moving Average Convergence Divergence, MACD*) predstavlja razliku između dva eksponencijalna pokretna proseka, brzog i sporog, odnosno 12-dnevnog i 26-dnevnog (Kirkpatrick II i Dahlquist, 2015).. Signalna linija je 9-dnevni eksponencijalni pokretni prosek i služi za prepoznavanje prilika za kupovinu i prodaju. Formula glasi:

$$MACD_{nm} = EMA_n - EMA_m \quad (6)$$

gde je EMA eksponencijalni pokretni prosek (eng. *Exponential Moving Average*).

2.3.5 Parabolički pokazatelj zaustavljanja i preokreta

Uloga paraboličkog stop i preokreta (eng. *Parabolic Stop and Reverse, SAR*) indikatora je prepoznavanje mogućih preokreta eksponencijalnog trenda. Kada cena pređe iznad SAR linije, trend se menja iz opadajućeg u rastući i obrnuto. Njegovo izračunavanje je iterativno, pomoću formule:

$$SAR_n = SAR_{n-1} + AF * (EP - SAR_{n-1}) \quad (7)$$

gde je EP ekstremna tačka trenda, AF faktor ubrzanja.

2.3.6 Bolindžerov kanal

Bolindžerov kanal (eng. *Bollinger Bands, BB*) se sastoji iz tri linije: srednji pokretni prosek i dve granice udaljene od srednjeg pokretnog proseka za k standardnih devijacija (Achelis, 2000). Kada se cene kreću blizu gornje granice, to ukazuje na preкупovanost, a kada se nalaze blizu donje na preprodatoš. Formule za dobijanje granica su:

$$GG_n = SMA_n + k\sigma_n \quad (8)$$

$$DG_n = SMA_n - k\sigma_n \quad (9)$$

gde je SMA_n srednji pokretni prosek za period n , σ standardna devijacija za period n .

2.3.7 Supertrend

Supertrend je indikator koji kombinuje informacije o volatilnosti i trendu pomoću indikatora prosečnog pravog raspona. Čine ga gornja i donja granica u odnosu na koje se gleda pozicija cene. Kada je cena iznad gornje granice, trend je rastući, a kada je iznad donje, trend je opadajući. Supertrend se računa na osnovu indikatora prosečnog pravog proseka (eng. *Average True Range, ATR*) i to korišćenjem sledećih formula:

$$GG_n = \frac{H_n + L_n}{2} + M * ATR_n \quad (10)$$

$$DG_n = \frac{H_n + L_n}{2} - M * ATR_n \quad (11)$$

gde je H_n najviša cena, L_n najniža cena, M množilac, ATR_n prosečan pravi raspon.

2.3.8 Indeks relativne snage

Indeks relativne snage (eng. *Relative Strength Index*, *RSI*) meri brzinu i promenu kretanja cena. Opseg vrednosti je od 0 do 100, pri čemu vrednosti iznad 70 označavaju prekupovanost, a vrednosti ispod 30 preprodatost.

$$RSI_n = 100 - \frac{100}{1 + RS_n} \quad (12)$$

gde je $RS_n = (\text{prosečan dobitak za period } n / \text{prosečan gubitak za period } n)$ (Rockefeller, 2020).

2.3.9 Indeks novčanog toka

Indeks novčanog toka (eng. *Money Flow Indeks*, *MFI*) povezuje cenu i obim trgovanja sa ciljem procene pritiska kupovine i prodaje. Vrednosti indeksa iznad 80 ukazuju na prekupovanost, a vrednosti ispod 20 na preprodatost (Kirkpatrick II i Dahlquist, 2015)..

Novčani tok za dan i se izračunava po formuli:

$$MF_n = TP_n * V_n \quad (13)$$

gde je TP_n tipična cena, a V_n obim za period n .

Kada podelimo sve pozitivne sa negativnim novčanim tokovima, dobijamo njihov odnos (eng. *Money Flow Ratio*, *MFR*):

$$MFR_n = \frac{\sum PMF}{\sum NMF} \quad (14)$$

gde je $\sum PMF$ ukupni pozitivni novčani tok, $\sum NMF$ ukupni negativni novčani tok.

Konačna formula za izračunavanje indeksa novčanog toka je:

$$MFI_n = 100 - \frac{100}{1 + MFR_n} \quad (15)$$

gde je MFR_n odnos pozitivnih i negativnih novčanih tokova za period n (Kirkpatrick II i Dahlquist, 2015).

2.3.10 Čandeov oscilator momentuma

Čandeov oscilator momentuma (*Chande Momentum Oscillator, CMO*) meri razliku između zbira pozitivnih i negativnih promena cena u određenom periodu. Osciluje između -100 i 100, dok vrednosti iznad +50 ukazuju na prekupovanost, a ispod -50 na preprodatoš (Rockefeller, 2020). Izračunava se po formuli:

$$CMO_n = 100 * \frac{\sum U - \sum D}{\sum U + \sum D} \quad (16)$$

gde je $\sum U$ ukupna pozitivna promena cene na zatvaranju, $\sum D$ ukupna negativna promena cene na zatvaranju.

2.3.11 Prosečni indeks smeru

Prosečni indeks smeru (eng. *Average Directional Index, ADX*) meri jačinu trenda, bez obzira na njegov pravac. Izračunava se pomoću indeksa pozitivnih i negativnih pravaca kretanja cene. Kreće se na intervalu od nula do 100, pri čemu vrednosti iznad 25 ukazuju na jak trend, a vrednosti ispod 20 na slab trend. Formula za izračunavanje:

$$ADX_n = 100 * EMA_n \left(\frac{|+DI_n - -DI_n|}{+DI_n + -DI_n} \right) \quad (17)$$

gde je EMA_n eksponencijalni pokretni prosek za period n , $+DI_n$ indeks pozitivnog pravca, $-DI_n$ indeks negativnog pravca za period n .

2.3.12 Indeks korelacije ranga

Indeks korelacije ranga (eng. *Rank Correlation Index, RCI*) meri korelaciju između redosleda dana u periodu i rangiranih cena zatvaranja. Vrednosti blizu 1 i -1 ukazuju na snažan rastući i opadajući trend, dok vrednosti oko nule ukazuju na nestabilno ili bočno kretanje cena. Formula:

$$RCI_n = 1 - \frac{(6 \sum d_i^2)}{n(n^2 - 1)} \quad (18)$$

gde je d_i razlika između redosleda i ranga za dan i , n dužina posmatranog perioda.

3 OPIS PROBLEMA

Tržište kriptovaluta je najvolatilnije finansijsko tržište današnjice, što predstavlja veliku prepreku u predviđanju kretanja i donošenju investicionih odluka. Za razliku od tradicionalnih berzanskih tržišta, vrednost kriptovaluta se formira isključivo na osnovu ponude i tražnje, bez centralne regulacije. Kao rezultat toga, cene kriptovaluta karakterišu brze i česte oscilacije, koje mogu biti uzrokovane različitim faktorima, od makroekonomskih vesti, regulatornih promena i tehnoloških inovacija, do kolektivnog investicionog ponašanja i spekulacija na tržištu.

Bitcoin, kao najpoznatija i najzastupljenija kriptovaluta, predstavlja dobar primer ovakvog tržišta koje čak i iskusnim investitorima otežava procenu optimalnog trenutka za kupovinu ili prodaju. Zbog toga je za predviđanje trenda njegove cene neophodno primeniti napredne metode mašinskog učenja, koje imaju mogućnost da prepoznaju skrivene relacije u podacima i da uče iz sekvenci vremenskih vrednosti. Model *LSTM* neuronskih mreža izabran je zbog njihove prilagođenosti sekvencijalnim podacima, kao što su vremenske serije finansijskih vrednosti, što omogućava prepoznavanje obrazaca koji se razvijaju tokom vremena.

Problem je posmatran iz dva ugla, kao klasifikacioni i kao regresioni. Pri rešavanju klasifikacionog problema, zadatak modela je da, na osnovu istorijskih podataka, klasifikuje sledeći dan kao rastući (1) ili opadajući (-1). Sa druge strane, kada se rešava regresioni problem, zadatak je predviđanje tačne vrednosti pokretnog proseka cene koja opisuje trend.

Međutim, sama cena kao ulazni signal ne daje dovoljno informacija o strukturi tržišta niti o njegovim kretanjima. Zbog toga se uvode tehnički indikatori kako bi se kvantifikovale pojave kao što su momentum, snaga trenda i volatilnost.

4 PREDLOŽENA METODOLOGIJA

U ovom poglavlju prikazan je razvoj modela za rešavanje opisanog problema. Implementacija je realizovana u *Python* programskom jeziku, korišćenjem *Spyder* razvojnog okruženja.

Python je interpretirani, objektno orijentisani i visokonivojski programski jezik otvorenog koda koji karakterišu dinamička semantika, jednostavna sintaksa i visoka čitljivost (www.python.org, 2025). Zahvaljujući velikom broju dostupnih biblioteka i modula, *Python* je postao jedan od najpopularnijih jezika u domenu nauke o podacima.

Tabela 1. Pregled korišćenih biblioteka

Biblioteka	Opis
<i>PyTorch</i>	Za izgradnju i treniranje neuronske mreže
<i>Scikit-learn</i>	Za obradu podataka, skaliranje i evaluaciju modela
<i>TA-Lib</i>	Za izračunavanje tehničkih indikatora
<i>Matplotlib</i>	Za vizuelizaciju i prikaz rezultata
<i>Pandas</i>	Za manipulaciju i analizu podataka
<i>NumPy</i>	Za matematičke i statističke operacije

U Tabeli 1 prikazane su korišćene biblioteke sa kratkim opisom njihovih osnovnih funkcionalnosti. Kombinacijom ovih alata omogućena je efikasna obrada, analiza i vizuelizacija podataka, kao i implementacija *LSTM* neuronske mreže.

Spyder (*Scientific Python Development Environment*) je integrisano razvojno okruženje (eng, *Integrated Development Environment, IDE*) otvorenog koda, specijalno namenjeno naučnom računarstvu i analizi podataka u programskom jeziku *Python* (www.spyder-ide.org, 2024). Objedinjuje funkcionalnosti interaktivne konzole, uređivača koda, analizatora performansi i vizuelizatora rezultata. Omogućava pisanje, izvršavanje i testiranje koda, kao i analiziranje toka i performansi programa u realnom vremenu.

Proces izrade modela obuhvata sledeće faze:

1. Preuzimanje i priprema podataka
2. Kreiranje ciljne promenljive
3. Formiranje niza ulaznih promenljivih
4. Kreiranje sekvenci podataka
5. Treniranje *LSTM* mreže
6. Evaluacija performansi

4.1 PREUZIMANJE I PRIPREMA PODATAKA

Istorijski podaci o vrednosti cene *Bitcoin*-a su preuzeti sa *Invest.com* i obuhvataju period od 26. januara 2014. do 26. jula 2025. godine. Skup podataka sadrži sledeće attribute:

- datum (*Date*);
- cena otvaranja (*Open*);
- cenu zatvaranja (*Price*);
- najviša dnevna cena (*High*);
- najniža dnevna cena (*Low*);
- obim trgovanja (*Vol.*);
- dnevna promena cene izražena u procentima (*Change %*).

Nakon učitavanja podataka, sprovedeno je čišćenje i priprema za dalji rad. Uklonjeni su svi nepotrebni karakteri (poput zareza, znaka za procenat i slovni oznaka za veličine), a zatim su svi atributi konvertovani u numerički tip podataka. Podaci su sortirani po datumu i *Date* kolona je postavljena kao indeks tabele. Na kraju su uklonjene sve opservacije koje sadrže nedostajuće vrednosti (eng. *NaN*).

4.2 KREIRANJE CILJNE PROMENLJIVE

Kako je zadatak predvideti trend cene *Bitcoin*-a, potrebno je definisati ciljnu promenljivu koja opisuje smer kretanja cene. Dva pristupa koja su razmatrana u okviru ovog istraživanja (klasifikacioni i regresioni) zahtevaju različito definisanje izlazne promenljive.

4.2.1 Klasifikacioni problem

Posmatrano kao problem klasifikacije, zadatak modela je da na osnovu istorijskih podataka o kretanju cene klasifikuje sledeći dan. Zbog toga je kao ciljna promenljiva dodata nova kolona *Trend* koja sadrži tri moguće vrednosti trenda:

- Rastući trend (1);
- Neutralan trend (0);
- Opadajući trend (-1).

Opservacije su klasifikovane na osnovu vrednosti iz *Change %* kolone, prema unapred definisanim intervalima za svaku klasu. Početni pristup definisanju intervala bio je određivanje granica za neutralnu klasu na osnovu srednje vrednosti prinosa i određenog procenta standardne devijacije oko nje, koristeći sledeće formule:

$$GG_n = \bar{x}_n + k\sigma_n \quad (19)$$

$$DG_n = \bar{x}_n - k\sigma_n \quad (20)$$

gde je $\bar{x}_n$ srednja vrednost prinosa za interval n , σ_n standardna devijacija prinosa za interval n , k množilac

Nakon nekoliko eksperimentalnih testiranja, određene su optimalne vrednosti za granice $GG_n = 0.8$ i $DG_n = -0.4$ za donju. Sve vrednosti iznad gornje granice pripadaju klasi rastućeg trenda, a sve vrednosti ispod donje klasi opadajućeg trenda.

Eksperiment je sproveden i sa tri, ali i sa dve klase, kada su u obzir uzete samo rastuća i opadajuća klasa. U slučaju binarne klasifikacije, kada god je prinos pozitivan, klasa je rastuća, a kada je negativan, opadajuća.

Pri analiziranju podataka, uočeno je devet slučajeva kada su cene zatvaranja za dva uzastopna dana bile identične, odnosno prinos je iznosio nula. Zbog veoma malog broja ovakvih slučajeva, oni su pridruženi rastućoj klasi, jer se iz perspektive trgovanja, sve što nije gubitak može smartati dobitkom.

4.2.2 Regresioni problem

U okviru regresionog pristupa, cilj modela je predviđanje numeričke vrednosti koja opisuje trend. Kao ciljna promenljiva koja se predviđa postavljen je desetodnevni pokretni prosek cene *Bitcoin*-a.

Kao referentna tačka, izvršeno je i predviđanje tačne vrednosti cene. Dobijeni rezultati korišćeni su za poređenje i proveru tačnosti predviđanja pokretnog proseka.

Nakon dobijanja predikcija pokretnog proseka cene, one su klasifikovane u dve, odnosno tri klase. Podela na tri klase izvršena je analogno pristupu podele u klasifikacionom problemu, ali na osnovu vrednosti prinosa pokretnog proseka cene. Konačne vrednosti koje su određene su 0.3 za gornju i -0.15 za donju granicu. Pri binarnoj klasifikaciji su vrednosti opet podeljena na rastuću i opadajuću klasu uz pridruživanje neutralnih slučajeva rastućoj klasi.

4.3 FORMIRANJE NIZA ULAZNIH PROMENLJIVIH

Ulazni signali za neuronsku mrežu su tehnički indikatori izračunati na osnovu preuzetih istorjskih podataka o *Bitcoin*-u. Većina indikatora se može lako izračunati metodama iz *TA-lib* biblioteke, dok su *Supertrend* i *RCI* implementirani ručno, zbog njihove ograničene podrške u dostupnim bibliotekama. Vrednosti svih dobijenih indikatora su zatim skalirane na interval od -1 do 1 radi konzistentnosti podataka.

Za klasifikacioni pristup, pored osnovnih vrednosti indikatora, za svaki od njih izračunat je i jednodnevni trend, koji pokazuje smer kretanja vrednosti indikatora između dva uzastopna dana. Konačan niz ulaznih parametara čine i vrednosti i trendovi svih izabranih indikatora zajedno, čime se proširuje skup informacija za proces učenja neuronske mreže.

U slučaju regresionog pristupa, za svaki od indikatora izračunati su njihovi pokretni proseci za period od deset dana. U konačni niz ulaznih signala uključene su samo te izglađene vrednosti.

4.4 KREIRANJE SEKVENCI PODATAKA

Za proces treniranja i testiranja mreže, podaci su podeljeni u dva skupa. Za razliku od uobičajene slučajne podele podataka, ovde je važno sačuvati vremenski redosled opservacija pa je prvih 80 posto stavljeno u skup za treniranje, a preostalih 20 posto u skup za testiranje.

Tabela 2. Raspodela opservacija na skup za treniranje i skup za testiranje

Skup za treniranje	Skup za testiranje
26.01.2014. - 08.04.2023	09.04.2023. - 26.07.2025.
3360 opservacija	840 opservacija

U Tabeli 2 prikazana je raspodela opservacija na skup za treniranje i skup za testiranje.

Kada su oba skupa kreirana, razdvojeni su ulazni od izlaznog parametra. U promenljive X_{train} i X_{test} smešteni su svi ulazni parametri, a u y_{train} i y_{test} izlazna promenljiva. Nad dobijenim skupovima se vrši pojedinačno MinMax skaliranje kako bi se svi podaci sveli na isti opseg i izbeglo curenje informacija iz trening u test skup.

Pošto *LSTM* mreže rade sa sekvencijalnim podacima, poslednji korak pripreme ulaza je kreiranje sekvenci od skaliranih podataka. Sekvence su kreirane funkcijom `create_sequence` kojoj se prosleđuje skup i željena dužina vremenskog prozora, koja je u ovom slučaju 15 dana. Rezultat su sekvence, svaka od po 15 uzastopnih dana, koje predstavljaju ulaz za *LSTM* neuronsku mrežu.

4.5 TRENIRANJE LSTM MREŽE

Arhitektura korišćene *LSTM* mreže sastoji se iz jednog *LSTM* sloja koji prima sekvence ulaznih promenljivih i uči obrasce kretanja cene. Izlaz *LSTM* sloja zatim ulazi u linearni sloj koji smanjuje dimenzionalnost i priprema podatke za nelinearnu transformaciju *ReLU* funkcijom aktivacije. Poslednji sloj je izlazni linearni sloj koji daje predikciju.

Treniranje je izvršeno korišćenjem funkcije gubitka unakrsne entropije (eng. *Cross-Entropy Loss*) funkcije koja meri razliku između stvarnih i predviđenih klasa, a optimizacija parametara mreže izvršena je *Adam* algoritmom koji prilagođava težine sa ciljem minimizacije funkcije greške. Po potrebi, da bi se sprečilo da dođe do preprilagođavanja mreže na podatke za treniranje, iskorišćeni su stopa ispuštanja (eng. *Dropout*), *L2* regularizacija (eng. *regularization*) i rano zaustavljanje (eng. *Early Stopping*).

Stopa ispuštanja ima zadatak da nasumično isključuje određeni procenat neurona tokom treniranja. *L2* regularizacija dodaje „kaznu“ funkciji gubitka koja je proporcionalna kvadratu težina kako bi se postiglo smanjenje velikih težina (eng. *weight decay*). Cilj ranog zaustavljanja je prekid treniranje kada performanse na validacionom skupu opadnu i ne pokazuju više poboljšanje u toku određenog broja epoha.

4.6 EVALUACIJA PERFORMANSI

Nakon treniranja *LSTM* mreže i dobijanja predviđanih vrednosti na test skupu, izračunate su standardne evaluacione metrike. Pregled ovih metrika daje uvid u uspešnost modela da predvidi trend cene *Bitcoin*-a.

Osnovni vid evaluacije klasifikacije je matrica konfuzije (eng. *confusion matrix*) (Milošević i dr, 2021). Ona prikazuje raspodelu tačnih i netačnih predikcija po klasama. Redovi matrice predstavljaju stvarne, a kolone predviđene klase. Klase se obeležavaju kao pozitivne i negativne, a poklapanje stvarne i predviđene klase sa tačno i netačno. Tako polja matrice imaju vrednosti stvarno pozitivne (eng. *true positive*, *TP*), lažno pozitivne (eng. *false positive*, *FP*), lažno negativne (eng. *false negative*, *FN*) i stvarno negativne (eng. *true negative*, *TN*). U slučaju ovog istraživanja, pozitivna klasa je klasa negativnog trenda.

		Predviđena klasa	
		P	N
Stvarna klasa	P	TP	FN
	N	FP	TN

Slika 6. Matrica konfuzije

Na Slici 6 je prikazan izgled matrice konfuzije za binarnu klasifikaciju. Na osnovu matrice konfuzije, izračunavaju se i ostale važne vrednosti za procenu uspešnosti klasifikacije (Milošević i dr, 2021). U Tabeli 3 dat je pregled metrika za klasifikaciju.

Tabela 3. Pregled metrika za klasifikaciju

Metrika	Opis	Formula
Tačnost (eng. <i>accuracy, acc</i>)	Procenat tačnih predikcija u odnosu na sve predikcije	$acc = \frac{TP + TN}{TP + FP + FN + TN}$
Preciznost (eng. <i>precision, p</i>)	Procenat tačno predviđenih pozitivnih primera prema ukupnom broju predviđenih pozitivnih primera	$p = \frac{TP}{TP + FP}$
Odziv (eng. <i>recall, r</i>)	Procenat tačno predviđenih pozitivnih primera prema ukupnom broju stvarno pozitivnih primera	$r = \frac{TP}{TP + FN}$
F1 metrika	Balans preciznosti i odziva, značaj modela	$F1 = \frac{2pr}{p + r}$

Zadatak regresije je određivanje tačnih numeričkih vrednosti promenljive koja se predviđa. Zato je fokus na odstupanju predviđenih od stvarnih vrednosti i ono se meri posebnim metrikama. U Tabeli 4 dat je pregled i opis metrika za regresiju.

Tabela 4. Pregled metrika za regresiju

Metrika	Opis
Prosečna kvadratna greška (eng. <i>Mean Squared Error, MSE</i>)	Prosečna kvadratna razlika između predviđene i stvarne vrednosti
Koeficijent determinacije, R^2	Procenat stvarnih varijacija koje model objašnjava

5 REZULTATI

U ovom poglavlju prikazani su rezultati opisanih modela na test skupu. Cilj analize je procena sposobnosti modela da prepozna obrasce u kretanju cene *Bitcoin*-a koji se formiraju kroz vreme i na osnovu njih predvidi trend. Klasifikacioni i regresioni modeli se evaluiraju razlicitim metrikama, pa su, radi lakšeg poređenja, predikcije regresionog modela naknadno klasifikovane.

Takođe, važno je primetiti da je treniranje neuronske mreže stohastički proces i svako pokretanje daje drugačiji rezultat nad istim podacima. Iz tog razloga je svaki model istreniran po 100 puta i za rezultate je uzet prosek svih dobijenih vrednosti na tih 100 pokretanja. Tako je obezbeđen tačan i realan prikaz performansi modela.

5.1 KLASIFIKACIONI PROBLEM

Tabela 5. Rezultati klasifikacije trenda na dve klase

	Preciznost	Odziv	F1
1	0,5579	0,3301	0,4097
-1	0,4976	0,7155	0,5853
Tačnost	0,5155		
F1	0,4942		

U Tabeli 5 je dat pregled rezultata dobijenih nakon predviđanja trenda klasifikacionim pristupom, kada je trend opisan sa dve klase.

Tačnost od 51,5% pokazuje da je predviđanje modela tek nešto bolje od slučajnog pogađanja za binarnu klasifikaciju. Vrednost F1 metrike od 0,49 takođe ukazuje na ograničenu uspešnost modela i da postoji dosta prostora za poboljšanje. Iz preciznosti i odziva po klasama, vidi se da model češće predviđa opadajući trend, ali je veliki deo tih predviđanja netačan, dok rastući trend predviđa ređe, ali sa većom tačnošću.

282	112
285	140

Slika 7. Matrica konfuzije sa dve klase

Na Slici 7 prikazana je matrica konfuzije za rezultate predviđanja trenda klasifikacionim pristupom, kada je trend opisan sa dve klase.

Konfuzionna matrica takođe ilustruje neuravnoteženost učestalosti predviđanja dve klase. Model je 282 puta tačno predvideo opadajući trend, ali još više puta (285) je netačno predvideo opadajući trend. Rastući trend je predviđen značajno manje puta uz nešto više tačnih predviđanja (140) naspam netačnih (121).

Tabela 6. Rezultati klasifikacije trenda na tri klase

	Preciznost	Odziv	F1
1	0,4017	0,3388	0,3441
0	0,1180	0,0023	0,004
-1	0,3749	0,7315	0,4885
Tačnost	0,3802		
F1	0,2942		

U Tabeli 6 dat je pregled rezultata dobijenih nakon predviđanja trenda klasifikacionim pristupom, kada je trend opisan sa tri klase.

Tačnost modela od 38% je ponovo tek malo bolja od slučajnog pogađanja koje je za tri klase 33,3%. Model prepoznaje određene obrasce, ali nedovoljno dobro da napravi značajniji iskorak od slučajne verovatnoće, što se vidi i iz niske vrednosti F1 metrike.

I nakon uvođenja treće klase, vidi se jasna pristrasnost modela opadajućoj klasi, ali sa niskom tačnošću njenog predviđanja. Dodata, neutralna klasa ima veoma niske vrednosti i preciznosti i odziva, što ukazuje da model ne uspeva da je prepozna i predvidi na osnovu ulaznih signala.

218	0	80
183	1	64
181	0	93

Slika 8. Matrica konfuzije sa tri klase

Na Slici 8 prikazana je matrica konfuzije za rezultate predviđanja trenda klasifikacionim pristupom, kada je trend opisan sa tri klase. Konfuzionna matrica dodatno potvrđuje slabu zastupljenost neutralne klase u predviđanjima, kao i izraženu sklonost redviđanju opadajuće klase.


5.2 REGRESIONI PROBLEM

Pre predviđanja pokretnog proseka cene, izvršeno je predviđanje tačne vrednosti cene, kako bi se dobio uvid u sposobnost modela za direktno predviđanje i procenilo da li je nastavak istraživanja u pravcu regresionog pristupa opravdan. Rezultati dobijeni za predviđanje tačne vrednosti cene iskorišćeni su za proveru i poređenje sa rezultatima predviđanja pokretnog proseka.

Tabela 7. Rezultati predviđanja cene i pokretnog proseka cene


	Predviđanje cene	Predviđanje 10-dnevnog pokretnog proseka cene
MSE	281.529.547 ± 247.330.640	161.781.408 ± 231.812.214
R²	0,6299 ± 0,3251	0,7827 ± 0,3114

U Tabeli 7 dat je uporedni prikaz rezultata predviđanja cene i desetodnevnog pokretnog proseka cene. Koeficijent determinacije za predviđanje cene govori da model uspešno opisuje otprilike 63% varijabiliteta stvarnih promena cene. Kada se iz prosečne kvadratne greške izvuče koren, dobija se prosečna greška od približno 16.777 američkih dolara, što u kontekstu visoke volatilnosti *Bitcoin*-a ukazuje da model uspeva da prati trend kretanja cene. Ovi rezultati ukazuje da model uspeva da uoči obrasce i predvidi vrednost sa određenom sigurnošću. Na Slici 9 prikazane su najbolje predviđene vrednosti i stvarne vrednosti cene na skupu za testiranje.



Slika 9. Predviđene i stvarne vrednosti cene

Iz srednje kvadratne greške koja je manja i koeficijenta determinacije koji je veći kod predviđanja pokretnog proseka, može se zaključiti da model preciznije predviđa ovu vrednost od direktne cene. Na Slici 10 prikazane su najbolje predviđene vrednosti i stvarne vrednosti pokretnog proseka cene za period od daset dana na skupu za testiranje.



Slika 10. Predviđene i stvarne vrednosti pokretnog proseka cene

Kako je predviđanje pokretnog proseka dalo zadovoljavajuće rezultate, istraživanje je nastavljeno klasifikovanjem dobijenih predikcija na dve, odnosno tri klase trenda. Zatim dobijene vrednosti upoređene sa stvarnim. U Tabeli 8 je dat pregled rezultata klasifikacije trenda na dve klase.

Tabela 8. Rezultati klasifikacije trenda na dve klase

	Preciznost	Odziv	F1
1	0,7511	0,7092	0,7294
-1	0,6349	0,6826	0,6577
Tačnost	0,6979		
F1	0,6988		

Tačnost od 69,7% ukazuje na solidnu uspešnost modela, kao i značajan napredak u odnosu na model sa klasifikacionim pristupom. Iz F1 vrednost od 0,698 vidi se da model dobro balansira preciznost i odziv, što se može zaključiti i iz vrednosti preciznosti i odziva po klasama. Ove vrednosti su za obe klase približno slične, bez velikog odstupanja, i zadovoljavajuće visoke.

237	110
136	331

Slika 11. Matrica konfuzije sa dve klase

Na Slici 11 prikazana je matrica konfuzije za rezultate predviđanja trenda regresionim pristupom, kada je trend opisan sa dve klase. Ona takođe ilustruje dobru izbalansiranost sa približno jednakim brojem predviđanja za obe klase i većim brojem tačnih procena u oba slučaja.

Tabela 9. Rezultati klasifikacije trenda na tri klase

	Preciznost	Odziv	F1
1	0,5905	0,6856	0,6324
0	0,3360	0,1736	0,2237
-1	0,5339	0,6820	0,5971
Tačnost	0,5278		
F1	0,4961		

U Tabeli 9 dat je pregled rezultata dobijenih nakon predviđanja trenda regresionim pristupom, kada je trend opisan sa tri klase. Kada se uključi i treća, neutralna klasa, zaključak ostaje isti kao i u slučaju binarne klasifikacije. Regresioni pristup i ovde pokazuje bolje performanse u odnosu na klasifikacioni. Međutim, ponovo se može uočiti loše prepoznavanje neutralne klase.

177	42	41
101	43	105
53	44	210

Slika 12. Matrica konfuzije sa tri klase

Na Slici 12 prikazana je matrica konfuzije za rezultate predviđanja trenda regresionim pristupom, kada je trend opisan sa dve klase. Rezultati rastuće i opadajuće klase pokazuju izbalansiranost predikcija i zadovoljavajuću tačnost, dok se kod neutralne klase vidi retkost i nesigurnost predviđanja.

6 ZAKLUČAK

Predviđanje trenda *Bitcoin*-a predstavlja složen zadatak, pa je trend u okviru ovog istraživanja posmatran i kao klasna i kao numerička promenljiva radi nalaženja najboljeg rešenja. Za njegovo predviđanje je iskorišćena *LSTM* mreža, koja ima sposobnost obrade sekvencijalnih finansijskih podataka. Kako bi se izvukle sve važne informacije iz cene *Bitcoin*-a, na osnovu nje su izračunati tehnički indikatori koji su prosleđeni mreži kao ulazni signali.

Nakon evaluacije rezultata dva različita pristupa predviđanju trenda, jasno je da *LSTM* neuronske mreže nemaju jednaku prediktivnu moć u oba slučaja. Eksperiment je pokazao da klasifikacioni pristup daje rezultate zanemarljivo bolje od verovatnoće slučajnog pogotka. Sa druge strane, regresioni pristup pokazuje značajan skok u uspešnosti tačnog predviđanja, kao i bolju izbalansiranost rezultata po klasama.

Međutim, kada se trend razvrstava u tri umesto dve klase, u oba slučaja dolazi do nesigurnosti pri predviđanju neutralne klase. Ovaj problem ukazuje na neadekvatne informacije iz ulaznih promenljivih, nebalansiranost klasa ili previše šuma u podacima i predstavlja prostor za dalju analizu i poboljšanje modela.

Na kraju, može se zaključiti da *LSTM* neuronske mreže imaju potencijal za predviđanje trenda kriptovaluta, ali uz određena ograničenja. Budući rad na projektu može se usmeriti na dodatno eksperimentisanje sa arhitekturom mreže, proširenje skupa indikatora i uvođenje metoda za balansiranje klasa kako bi se pre svega poboljšalo prepoznavanje neutralnog trenda, ali i performanse celog modela.

LITERATURA

- Achelis, S. (2000) *Technical Analysis from A to Z*, McGraw-Hill, New York.
- Aggarwal, C. (2018) *Neural Networks and Deep Learning*, Springer, Cham.
- Antonopoulos, A. (2017) *Mastering Bitcoin: Programming the Open Blockchain*, O`Reilly Media, Sebastopol.
- Brownlee, J. (2017) *Long Short-Term Memory Networks with Python*, Machine Learning Mastery, Melbourne.
- Edwards, R., Magee, J., Basetti, W. (2019) *Technical Analysis of Stock Trends*, CRC Press, Boca Raton.
- Gurney, K. (1997) *An introduction to Neural Networks*, UCL Press, London.
- Haykin, S. (2009) *Neural Networks and Learning Machines*, Pearson, Upper Saddle River.
- Kirkpatrick II, C., Dahlquist, J. (2015) *Technical Analysis: The Complete Resource for Financial Market Technicians*, Pearson, Upper Saddle River.
- McNelis, P. (2005) *Neural Networks in Finance: Gaining Predictive Edge in the Market*, Academic Press, Amsterdam
- Python.org (2025) [<https://www.python.org/doc/essays/blurb/> , datum pristupa: 09.10.2025.]
- Milošević, P., Rakićević, A., Dragović, I., Poledica, A., Petrović, B., Vukićević, A., Zukanović, M. (2021) *Računarska Inteligencija: praktikum u MATLAB-u*, Fakultet Organizacionih Nauka, Beograd
- Rockefeller, B. (2020) *Technical Analysis for Dummies*, John Wiley & Sons, Hoboken .
- Schueffel, P., Groeneweg, N., Baldegger, R. (2019) *The Crypto Encyclopedia*, Business School Lausanne Press, Lausanne.

Spyder-ide.org (2024) [<https://www.spyder-ide.org/about> , datum pristupa: 09.10.2025.]

Yaga, D., Mell, P., Roby, N., Scarfone, K. (2018) *Blockchain Technology Overview*, National Institute of Standards and Technology, Gaithersburg.